LLM-ассистент для абитуриентов

Команда: Антикислые

Введение

Цель проекта: Разработать интеллектуального ассистента для абитуриентов, который автоматически отвечает на вопросы о поступлении, использует реальные данные (таблицы + документы), минимизирует ошибки и галлюцинации

Задачи:

1. Классифицировать тип запроса: FAQ / SQL / RAG / некорректный
2. Реализовать retrieval: поиск по базе знаний (FAISS + embeddings)
3. Обработать табличные запросы: генерация SQL, извлечение точных значений
4. Генерировать ответы через LLM
5. Добавить проверку: **corrective RAG (anti-hallucination)**
6. Реализовать модерацию:фильтр токсичных запросов

Типы вопросов

Тип запроса/класс разметки	Пример
FAQ/0	1. Есть ли у РАНХиГС мобильное приложение для абитуриентов? 2. Есть ли БРС? Как она реализована?
RAG/1	1. Кто директор ИЭМИТ Президентской Академии ? 2. Релизуется ли программы военной подготовки в Президентской Академии?
SQL/2	1. Сколько бюджетных мест было в 2025 году на программе интегрированная логистика на региональных и глобальных рынках? 2. Сколько стоит обучение на программе финансы и кредит?
Автоответ/3	1. Эй ты, что-то долго отвечаешь и тормозишь, поторапливайся, я хочу узнать свои шансы на поступление? 2. Шайтан-машина плохо работает, а мне потом на платке платить за то, чтобы потом такую шнягу студенты делали за мои деньги?

Выбор моделей

Проблема: LLM склонны к галюцинациям, в задаче нельзя ошибкаться (баллы ЕГЭ, стоимость) RAG решает эту проблему. **Преимущества**:

- Лёгкая модель → работает локально
- Поддерживает инструкции
- Быстрая генерация (важно для latency)

Использовалось: Qwen/Qwen2.5-1.5B-Instruct, mistral

Retrieval (embedding): intfloat/multilingual-e5-base. **Преимущества** embeddings:

1. Хорошо работает с русским языком
2. Поддерживает query/passage формат
3. Даёт устойчивый semantic search

Реранкинг: cross-encoder/ms-marco-MiniLM-L-6-v2. **Преимущества**: улучшает качество top-k, сортирует документы по релевантности, лёгкий и быстрый.

SQL генерация. Преимущества: универсальность, можно контролировать через prompt, гибкость (разные типы запросов).

Corrective RAG (проверка). Используется LLM как оценщик (hallucination check, answer relevance check). **Преимущества**: можно иметь критерии проверки через промпт, не нужен отдельный классификатор, не нужна дополнительная модель LLM.

Общий pipeline

Вопрос пользователя → Классификация (route_node)

↳ **RAG → Retrieval (FAISS) → Reranker LLM → Corrective RAG → Ответ**

↳ **SQL → Генерация SQL → DB запрос → Ответ**

↳ **FAQ → Поиск в FAISS → Ответ**

↳ **Autoanswer → Фильтр точности**

Архитектура

Route

- ↳ **autoanswer → END**
- ↳ **FAQ → END**
- ↳ **SQL → END**
- ↳ **retrieve**

  ↓

  reranker → generate → grader

  - ↳ **useful → END**
  - ↳ **not useful → autoanswer**
  - ↳ **not supported → generate (loop)**
  - ↳ **max retries → END**

Corrective RAG

Corrective RAG – это дополнительный этап проверки ответа LLM на соответствие найденным данным.

Принцип работы:

1. Обычный RAG: нашёл документы → сгенерировал ответ
2. Corrective RAG: нашёл документы → сгенерировал ответ → проверил → подтвердил или отклонил

Используется: LLM: Qwen2.5-1.5B-Instruct и промпт.

Логика принятия решения:

- if useful → вернуть ответ
- if not useful → autoanswer
- if hallucination → regenerate
- if max retries → stop

Система выбирает: **Надёжность > Полнота** , т.е. лучше не найти нужное, чем дать неверный ответ.

Интерфейс

Реализация через **streamlite**. **Функционал**:

1. Поле ввода запроса. Пользователь вводит вопрос на естественном языке

2. Кнопка отправки. Запускает полный pipeline: классификация, retrieval, генерация

3. Блок ответа. Отображается итоговый ответ системы, краткий и понятный для пользователя

За счет того, как сформулирован ответ на запрос, можно понять тип запроса (FAQ / RAG / SQL / Auto).

Перед обработкой производится проверка на токсичность. Использование словарей: ru_abusive_words, ru_curse_words

Streamlite

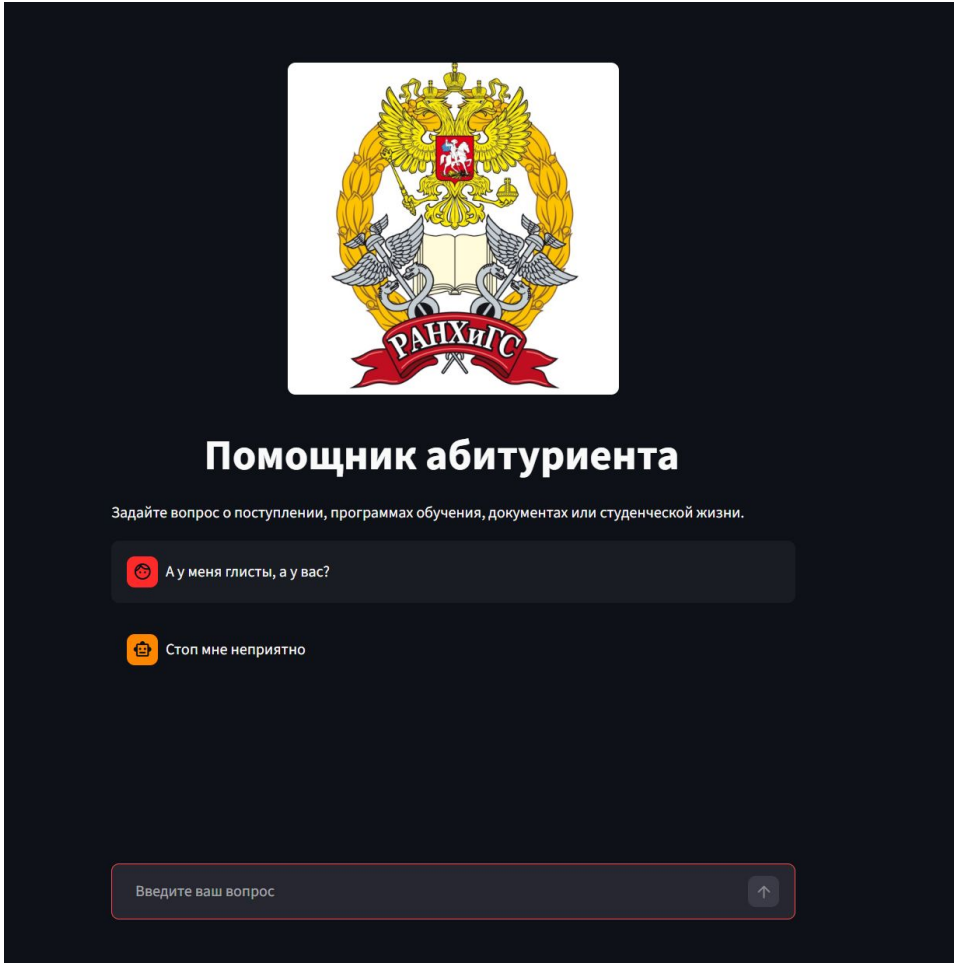
РАНХиГС
Помощник абитуриента
Задайте вопрос о поступлении, программах обучения, документах или студенческой жизни.
А у меня глисты, а у вас?
Стоп мне неприятно
Введите ваш вопрос

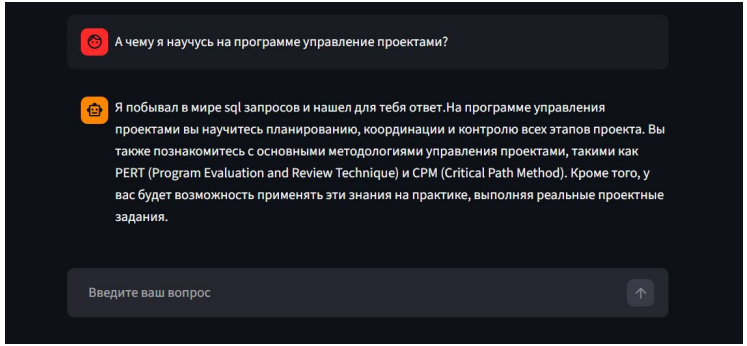
А чему я научусь на программе управление проектами?
Я побывал в мире sql запросов и нашел для тебя ответ.На программе управления проектами вы научитесь планированию, координации и контролю всех этапов проекта. Вы также познакомитесь с основными методологиями управления проектами, такими как PERT (Program Evaluation and Review Technique) и CPM (Critical Path Method). Кроме того, у вас будет возможность применять эти знания на практике, выполняя реальные проектные задания.
Введите ваш вопрос

Streamlite

Как внести оплату за учебу в университете, что надо сделать?

Здравствуйте! Рад помочь с вопросом о поступлении.

Чтобы внести оплату за учебу в университете, вам нужно выполнить несколько шагов:

1. Подайте заявление о приеме.
2. Подайте документ, удостоверяющий личность и гражданство.
3. Подайте документ об образовании.
4. Подайте документы, подтверждающие индивидуальные достижения (если они есть).
5. Подайте дополнительные документы для особых категорий поступающих.

После этого ваше заявление будет рассмотрено, и если все условия будут соблюдены, вы сможете получить место в университете.

Если у вас возникнут еще вопросы, не стесняйтесь обращаться к нам. Мы всегда готовы помочь!

С уважением, [Ваше имя]
[Адрес]
[Телефон]

Введите ваш вопрос

Где найти информацию о стоимости обучения?

Здравствуйте!

Чтобы узнать стоимость обучения, вам следует обратиться к официальному сайту РАНХиГС. Вы можете его найти по адресу: https://www.ranepa.ru/. На сайте указано, что стоимость обучения зависит от выбранного направления и уровня образования. Также стоит учесть, что существуют различные программы финансирования, такие как государственные стипендии и льготы для студентов с ограниченными financial needs.

Если у вас возникнут еще вопросы, пожалуйста, обращайтесь в приемную комиссию по телефону +7 (925) 390-05-95 или через электронную почту intensive@ranepa.ru. Мы всегда готовы помочь вам в этом процессе.

Введите ваш вопрос

Метрики

Метрика	Значение
Accuracy	0.7
F1-macro	0.692
F1-micro	0.7

Разбивка по классам			
Класс	Precision	Recall	F1
FAQ	0.875	0.5	0.636
RAG	0.5	1	0.667
SQL	1.00	0.5	0.667
Auto	0.7143	0.909	0.8

Retrieval метрики. Общие результаты.

Метрика	Значение
Cosine similarity	0.535
BLEU-1	0.3139
FAQ accuracy	0.5
Top-1	0.15
Top-3	0.2
Top-5	0.225

Метрика	Значение
Доля корректных ответов	0.78
"Не найдено"	0.35
Токсичные запросы	1.00

Итог и улучшения.

Построена полноценная **RAG-система**

Интегрированы:

- FAQ
- SQL
- текстовая база

Реализован:

- retrieval (FAISS + embeddings)
- reranking
- LLM генерация
- corrective pipeline

Как улучшить систему

1. Retrieval
hybrid search (BM25 + embeddings)
cross-encoder reranking (улучшить)
query rewriting
2. Классификация
дообучение модели
LLM classifier
confidence threshold
3. Corrective RAG
сделать менее строгим
добавить частичное принятие ответа
4. SQL
улучшить prompt
добавить валидацию запросов
5. Данные
нормализация названий
заполнение пропусков