LLM-ассистент для абитуриентов

Команда: Антикислые

Введение

Цель проекта: Разработать интеллектуального ассистента для абитуриентов, который автоматически отвечает на вопросы о поступлении, использует реальные данные (таблицы + документы), минимизирует ошибки и галлюцинации

Задачи:

1. Классифицировать тип запроса: FAQ / SQL / RAG / некорректный
2. Реализовать retrieval: поиск по базе знаний (FAISS + embeddings)
3. Обработать табличные запросы: генерация SQL, извлечение точных значений
4. Генерировать ответы через LLM
5. Добавить проверку: **corrective RAG (anti-hallucination)**
6. Реализовать модерацию:фильтр токсичных запросов

Типы вопросов

Тип запроса/класс разметки	Пример
FAQ/0	1. Есть ли у РАНХиГС мобильное приложение для абитуриентов? 2. Есть ли БРС? Как она реализована?
RAG/1	1. Кто директор ИЭМИТ Президентской Академии ? 2. Релизуется ли программы военной подготовки в Президентской Академии?
SQL/2	1. Сколько бюджетных мест было в 2025 году на программе интегрированная логистика на региональных и глобальных рынках? 2. Сколько стоит обучение на программе финансы и кредит?
Автоответ/3	1. Эй ты, что-то долго отвечаешь и тормозишь, поторапливайся, я хочу узнать свои шансы на поступление? 2. Шайтан-машина плохо работает, а мне потом на платке платить за то, чтобы потом такую шнягу студенты делали за мои деньги?

Выбор моделей

Проблема: LLM склонны к галюцинациям, в задаче нельзя ошибкаться (баллы ЕГЭ, стоимость) RAG решает эту проблему. **Преимущества**:

- Лёгкая модель → работает локально
- Поддерживает инструкции
- Быстрая генерация (важно для latency)

Использовалось: Qwen/Qwen2.5-1.5B-Instruct, mistral

Retrieval (embedding): intfloat/multilingual-e5-base. **Преимущества** embeddings:

1. Хорошо работает с русским языком
2. Поддерживает query/passage формат
3. Даёт устойчивый semantic search

Реранкинг: cross-encoder/ms-marco-MiniLM-L-6-v2. **Преимущества**: улучшает качество top-k, сортирует документы по релевантности, лёгкий и быстрый.

SQL генерация. Преимущества: универсальность, можно контролировать через prompt, гибкость (разные типы запросов).

Corrective RAG (проверка). Используется LLM как оценщик (hallucination check, answer relevance check). **Преимущества**: можно иметь критерии проверки через промпт, не нужен отдельный классификатор, не нужна дополнительная модель LLM.

Общий pipeline

Вопрос пользователя → Классификация (route_node)

↳ **RAG → Retrieval (FAISS) → Reranker LLM → Corrective RAG → Ответ**

↳ **SQL → Генерация SQL → DB запрос → Ответ**

↳ **FAQ → Поиск в FAISS → Ответ**

↳ **Autoanswer → Фильтр точности**

Архитектура

Route

- ↳ **autoanswer → END**
- ↳ **FAQ → END**
- ↳ **SQL → END**
- ↳ **retrieve**

  ↓

  reranker → generate → grader

  - ↳ **useful → END**
  - ↳ **not useful → autoanswer**
  - ↳ **not supported → generate (loop)**
  - ↳ **max retries → END**

Corrective RAG

Corrective RAG – это дополнительный этап проверки ответа LLM на соответствие найденным данным.

Принцип работы:

1. Обычный RAG: нашёл документы → сгенерировал ответ
2. Corrective RAG: нашёл документы → сгенерировал ответ → проверил → подтвердил или отклонил

Используется: LLM: Qwen2.5-1.5B-Instruct и промпт.

Логика принятия решения:

- if useful → вернуть ответ
- if not useful → autoanswer
- if hallucination → regenerate
- if max retries → stop

Система выбирает: **Надёжность > Полнота** , т.е. лучше не найти нужное, чем дать неверный ответ.

Интерфейс

Реализация через **streamlite**. **Функционал**:

1. Поле ввода запроса. Пользователь вводит вопрос на естественном языке

2. Кнопка отправки. Запускает полный pipeline: классификация, retrieval, генерация

3. Блок ответа. Отображается итоговый ответ системы, краткий и понятный для пользователя

За счет того, как сформулирован ответ на запрос, можно понять тип запроса (FAQ / RAG / SQL / Auto).

Перед обработкой производится проверка на токсичность. Использование словарей: ru_abusive_words, ru_curse_words

Streamlite

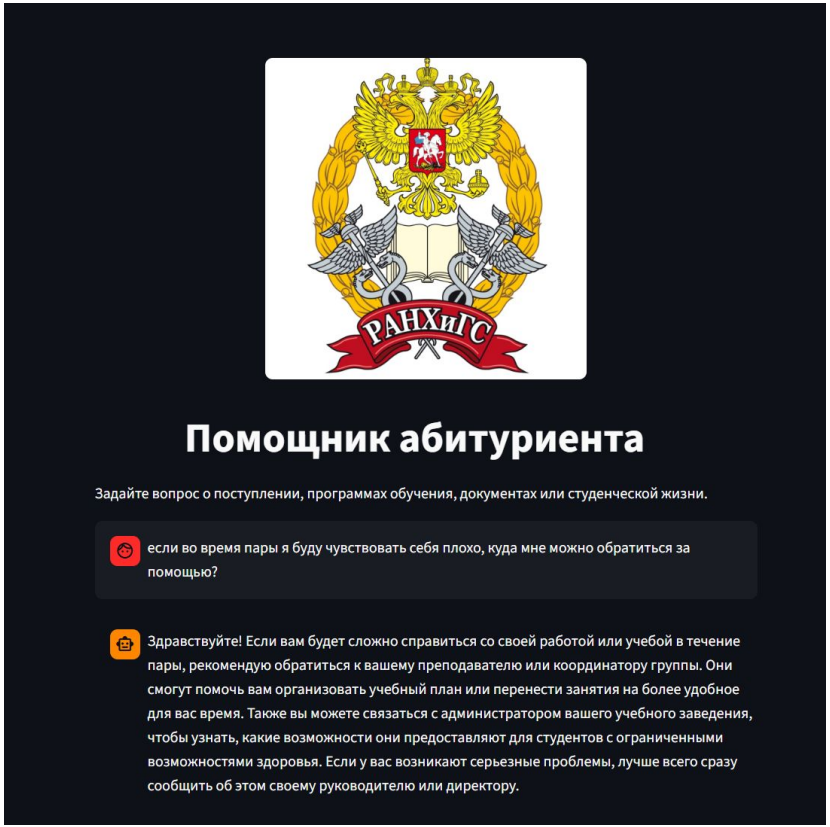
РАНХиГС
Помощник абитуриента
Задайте вопрос о поступлении, программах обучения, документах или студенческой жизни.
если во время пары я буду чувствовать себя плохо, куда мне можно обратиться за помощью?
Здравствуйте! Если вам будет сложно справиться со своей работой или учебой в течение пары, рекомендую обратиться к вашему преподавателю или координатору группы. Они смогут помочь вам организовать учебный план или перенести занятия на более удобное для вас время. Также вы можете связаться с администратором вашего учебного заведения, чтобы узнать, какие возможности они предоставляют для студентов с ограниченными возможностями здоровья. Если у вас возникают серьезные проблемы, лучше всего сразу сообщить об этом своему руководителю или директору.

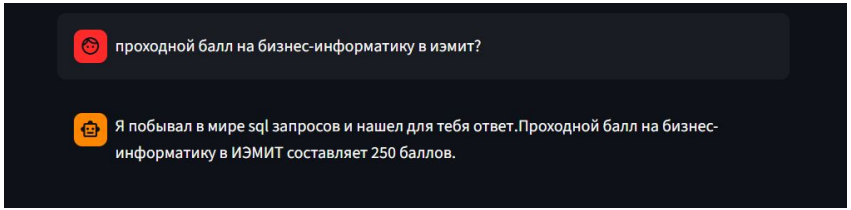
проходной балл на бизнес-информатику в иэмит?
Я побывал в мире sql запросов и нашел для тебя ответ.Проходной балл на бизнес-информатику в ИЭМИТ составляет 250 баллов.

Streamlite

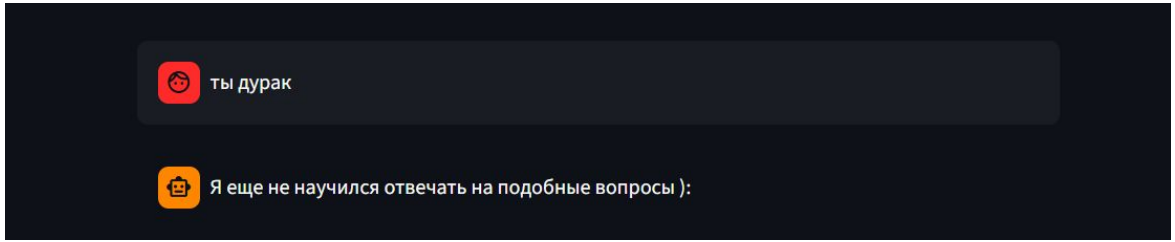
ты дурак
Я еще не научился отвечать на подобные вопросы):

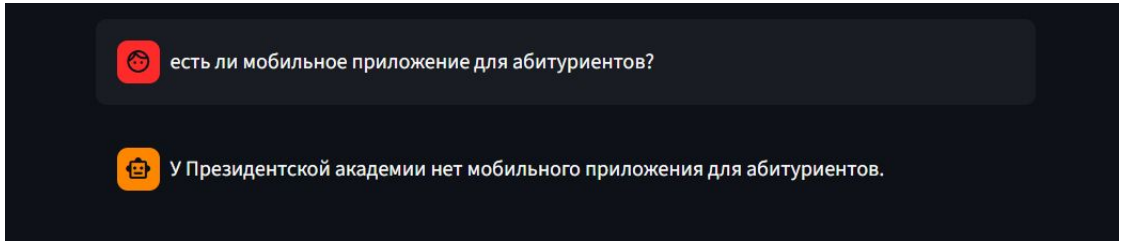
есть ли мобильное приложение для абитуриентов?
У Президентской академии нет мобильного приложения для абитуриентов.

Метрики

Метрика	Значение
Accuracy	0.7
F1-macro	0.692
F1-micro	0.7

Разбивка по классам			
Класс	Precision	Recall	F1
FAQ	0.875	0.5	0.636
RAG	0.5	1	0.667
SQL	1.00	0.5	0.667
Auto	0.7143	0.909	0.8

Retrieval метрики. Общие результаты.

Метрика	Значение
Cosine similarity	0.535
BLEU-1	0.3139
FAQ accuracy	0.5
Top-1	0.15
Top-3	0.2
Top-5	0.225

Метрика	Значение
Доля корректных ответов	0.78
"Не найдено"	0.35
Токсичные запросы	1.00

Итог и улучшения.

Построена полноценная **RAG-система**

Интегрированы:

- FAQ
- SQL
- текстовая база

Реализован:

- retrieval (FAISS + embeddings)
- reranking
- LLM генерация
- corrective pipeline

Как улучшить систему

1. Retrieval
hybrid search (BM25 + embeddings)
cross-encoder reranking (улучшить)
query rewriting
2. Классификация
дообучение модели
LLM classifier
confidence threshold
3. Corrective RAG
сделать менее строгим
добавить частичное принятие ответа
4. SQL
улучшить prompt
добавить валидацию запросов
5. Данные
нормализация названий
заполнение пропусков